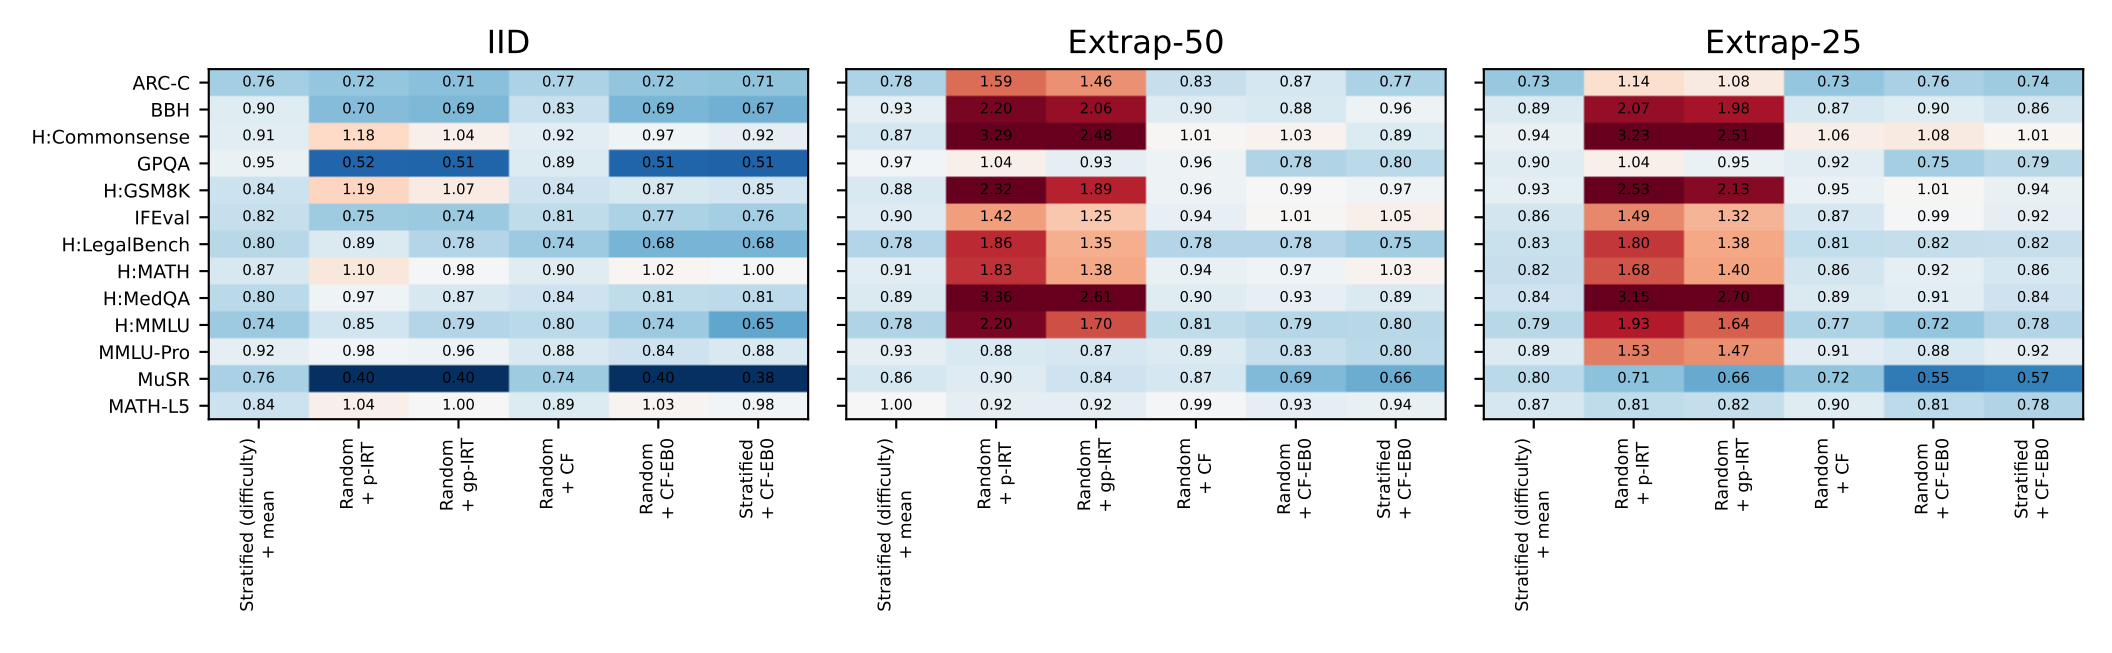
IID
Extrap-50
Extrap-25
ARC-C 0.76 0.72 0.71 0.77 0.72 0.71
BBH 0.90 0.70 0.69 0.83 0.69 0.67
H:Commonsense 0.91 1.18 1.04 0.92 0.97 0.92
GPQA 0.95 0.52 0.51 0.89 0.51 0.51
H:GSM8K 0.84 1.19 1.07 0.84 0.87 0.85
IFEval 0.82 0.75 0.74 0.81 0.77 0.76
H:LegalBench 0.80 0.89 0.78 0.74 0.68 0.68
H:MATH 0.87 1.10 0.98 0.90 1.02 1.00
H:MedQA 0.80 0.97 0.87 0.84 0.81 0.81
H:MMLU 0.74 0.85 0.79 0.80 0.74 0.65
MMLU-Pro 0.92 0.98 0.96 0.88 0.84 0.88
MuSR 0.76 0.40 0.40 0.74 0.40 0.38
MATH-L5 0.84 1.04 1.00 0.89 1.03 0.98
0.78 1.59 1.46 0.83 0.87 0.77
0.93 2.20 2.06 0.90 0.88 0.96
0.87 3.29 2.48 1.01 1.03 0.89
0.97 1.04 0.93 0.96 0.78 0.80
0.88 2.32 1.89 0.96 0.99 0.97
0.90 1.42 1.25 0.94 1.01 1.05
0.78 1.86 1.35 0.78 0.78 0.75
0.91 1.83 1.38 0.94 0.97 1.03
0.89 3.36 2.61 0.90 0.93 0.89
0.78 2.20 1.70 0.81 0.79 0.80
0.93 0.88 0.87 0.89 0.83 0.80
0.86 0.90 0.84 0.87 0.69 0.66
1.00 0.92 0.92 0.99 0.93 0.94
0.73 1.14 1.08 0.73 0.76 0.74
0.89 2.07 1.98 0.87 0.90 0.86
0.94 3.23 2.51 1.06 1.08 1.01
0.90 1.04 0.95 0.92 0.75 0.79
0.93 2.53 2.13 0.95 1.01 0.94
0.86 1.49 1.32 0.87 0.99 0.92
0.83 1.80 1.38 0.81 0.82 0.82
0.82 1.68 1.40 0.86 0.92 0.86
0.84 3.15 2.70 0.89 0.91 0.84
0.79 1.93 1.64 0.77 0.72 0.78
0.89 1.53 1.47 0.91 0.88 0.92
0.80 0.71 0.66 0.72 0.55 0.57
0.87 0.81 0.82 0.90 0.81 0.78
Stratified (difficulty) + mean
Random + p-IRT
Random + gp-IRT
Random + CF
Random + CF-EB0
Stratified + CF-EB0